

Dane Bez Twarzy

Automatyczna anonimizacja danych osobowych w języku polskim

Zespół: Application Fail Successfully

HackNation 2025 | 06.12.2025-07.12.2025

Slajd 1: Problem i Rozwiązanie

Problem

- Potrzeba anonimizacji danych osobowych (PII) w tekstach polskich
- Skomplikowana fleksja języka polskiego
- Konieczność rozróżniania kontekstu ({city} vs {address})
- Wymaganie: rozwiązanie offline, skalowalne

Nasze rozwiązanie

Hybrydowe podejście: RegEx + spaCy + LLM

- **Moduł 1:** Anonimizacja (RegEx + spaCy + priv_masker)
- **Moduł 2:** Synteza danych (3-fazowy pipeline z LLM)

Slajd 2: Architektura - 3-fazowy Pipeline

Moduł Syntezy Danych

```
Input: "[name] [surname] mieszka w [city]"
↓
Faza 1 (Faker): "Anna Kowalska mieszka w Warszawa"
↓
Faza 2 (LLM Fill): [Pominięta - optymalizacja!]
↓
Faza 3 (LLM Morphology): "Anna Kowalska mieszka w Warszawie"
↓
Output: "Anna Kowalska mieszka w Warszawie"
```

Kluczowe cechy

- ✓ **Optymalizacja:** Faza 2 pomijana jeśli Faker obsłużył wszystkie tokeny
- ✓ **Korekta morfologii:** Poprawa przypadków, form czasowników
- ✓ **Streaming:** Zapis wyników na bieżąco
- ✓ **Offline:** Lokalny Ollama lub PLLuM API

Slajd 3: Walka z Fleksją - Przykłady

Przykład 1: Miejscownik

Input: **Mieszkam** w [city]

Output: **Mieszkam** w Radomiu ✓

Błąd: **Mieszkam** w Radom ✗

Przykład 2: Zgodność rodzaju

Input: [name] [surname] prosił o pomoc

Output (męskie): Jan Kowalski prosił o pomoc ✓

Output (żeńskie): Anna Kowalska prosiła o pomoc ✓

Przykład 3: Kompleksowy adres

Input: **Mój adres** to [address]

Output: **Mój adres** to ulica Długa 15, kod pocztowy 00-001, miasto Warszawa

Slajd 4: Technologie i Wydajność

Stack technologiczny

- **RegEx**: Struktury stałe (PESEL, e-maile, telefony)
- **spaCy (pl_nask)**: Analiza morfologiczna i NER
- **priv_masker**: Wykrywanie i maskowanie PII
- **Faker (pl_PL)**: Generowanie syntetycznych danych
- **PLLuM**: Model językowy (online API lub lokalny Ollama)

Wydajność

- **Faza 1 (Faker)**: ~0.001s na linię
- **Faza 2 (LLM Fill)**: ~1-3s na linię (warunkowo)
- **Faza 3 (LLM Morphology)**: ~1-3s na linię
- **Średnio**: 26-30 sekund na linię (z LLM)

Hardware

- **CPU**: AMD Ryzen 9 7950X
- **GPU**: NVIDIA GeForce RTX 4080
- **Tryb**: Online (PLLuM API) + Lokalny (Ollama)

Slajd 5: Wyniki i Pomysłowość

Obsługiwane kategorie

Wszystkie **24+ kategorii PII** z wymagań:

- Dane osobowe: {name}, {surname}, {age}, {date-of-birth}, {sex}
- Lokalizacja: {city}, {address}
- Kontakt: {email}, {phone}
- Dokumenty: {pesel}, {document-number}
- Wrażliwe: {health}, {political-view}, {relative}, {ethnicity}
- I wiele więcej...

Funkcjonalności

- ✓ REST API + CLI
- ✓ Streaming output (wyniki widoczne natychmiast)
- ✓ Obsługa fleksji polskiej
- ✓ Rozróżnianie kontekstu ({city} vs {address})
- ✓ Optymalizacja TEKST_JEST_TAKI_SAM (oszczędność tokenów)

Pomysłowość podejścia

1. **Hybrydowe podejście:** Szybki Faker + inteligentny LLM
2. **3-fazowy pipeline:** Z warunkową Fazą 2 (optymalizacja)
3. **Dedykowana Faza 3:** Korekta morfologii przez LLM
4. **Streaming:** Zapis na bieżąco - nie tracimy danych przy przerwaniu

Dziękujemy za uwagę!

Application Fail Successfully

HackNation 2025